Лабораторна робота №4
Розподілена обробка великих даних із використанням Apache Spark

Завдання до лабораторної роботи

Для виконання лабораторної роботи використати набір даних **`online_retail_II.csv`**.

1. **Налаштувати середовище PySpark**

Створити `SparkSession` та виконати підключення до Apache Spark. Вивести основні параметри створеної Spark-сесії.

2. **Завантажити та дослідити дані**

Завантажити `online_retail_II.csv` у Spark DataFrame. Визначити кількість записів, кількість стовпців, типи даних та структуру набору.

3. **Виконати попередню обробку даних**

Виконати очищення даних від некоректних та пропущених значень. Перетворити необхідні стовпці до відповідних типів та створити стовпець `Revenue`.

4. **Виконати операції фільтрації та вибірки**

За допомогою операцій Spark DataFrame виконати вибір необхідних стовпців та фільтрацію записів за заданими умовами.

5. **Виконати групування та агрегацію даних**

Використати операції `groupBy()` та агрегатні функції для визначення основних показників продажів за товарами, клієнтами та країнами.

6. **Дослідити механізм розбиття даних на частини**

Визначити кількість `partitions` створеного DataFrame. Змінити кількість партицій та дослідити її вплив на виконання операцій над даними.

7. **Реалізувати обробку даних із використанням RDD**

Перетворити частину даних із DataFrame у RDD та виконати над ними операції `map()`, `filter()` та `reduce()`.

8. **Дослідити принципи Transformation та Action**

Для створених операцій визначити, які з них є `transformation`, а які – `action`. Простежити виконання операцій із урахуванням принципу `lazy evaluation`.

9. **Порівняти обробку даних у Pandas та PySpark**

Реалізувати однакову операцію аналізу набору даних у Pandas та PySpark. Виміряти час виконання та порівняти отримані результати.

10. **Дослідити ефективність розподіленої обробки**

Провести експеримент із різною кількістю `Partition`. Для кожного варіанта виміряти час виконання операції, порівняти результати та сформулювати висновок щодо впливу розподілу даних на продуктивність Apache Spark (*Для кожного комп'ютера можливі різні показники, в когось результати можуть бути гірші при паралельній обробці ніж при послідовній*).